




# Sistemas de Armazenamento Físico

Uma visão abrangente sobre como os dados são fisicamente armazenados, acessados e protegidos em sistemas de bancos de dados modernos.



Eduardo Ogasawara

[eogasawara@cefet-rj.br](mailto:eogasawara@cefet-rj.br) | <https://eic.cefet-rj.br/~eogasawara>



As mídias de armazenamento se dividem em **voláteis** (perdem dados sem energia) e **não-voláteis** (mantêm dados mesmo sem alimentação elétrica).

---

### Velocidade de Acesso

O tempo de recuperação varia de nanossegundos em cache a segundos em fitas magnéticas, determinando a adequação para cada aplicação.

---

### Custo por Unidade

Tecnologias mais rápidas geralmente apresentam custo por byte significativamente mais elevado, influenciando diretamente as decisões arquiteturais.

---

### Confiabilidade

Diferentes mídias oferecem níveis variados de durabilidade e resistência a falhas, sendo crucial para a integridade dos dados ao longo do tempo.

A hierarquia de armazenamento organiza tecnologias de memória equilibrando velocidade, capacidade e custo.

---

### Armazenamento Primário

Registradores e cache do processador.

---

### Armazenamento Volátil

Memória principal (RAM).

---

### Armazenamento Não-Volátil

Flash e memória persistente.

---

### Armazenamento Secundário

Discos magnéticos e SSDs.

---

### Armazenamento Terciário

Fitas magnéticas e mídia óptica.

---

### Cache: 1–5 nanossegundos

Acesso extremamente rápido, por linha de cache.

---

### Memória Principal: 60–100 nanossegundos

Acesso por linha de cache, ainda muito rápido.

---

### Flash/SSD: 20–100 microssegundos

Acesso por página, ordens de magnitude mais lento.

---

### Disco Magnético: 5–10 milissegundos

Inclui tempo de busca mecânica.

---

### Fita Magnética: 100+ milissegundos

Acesso sequencial com tempo de posicionamento significativo.

---

## **Cabeça de leitura/escrita**

Componente que magnetiza e detecta padrões magnéticos na superfície do disco.

---

## **Setores**

Menor unidade de dados que pode ser lida ou escrita, tipicamente 512 bytes.

---

## **Processo de Leitura/Escrita**

O braço posiciona a cabeça sobre a trilha correta, o prato gira (5.400–15.000 RPM) e os dados são lidos ou escritos conforme o setor passa sob a cabeça.

---

## **Trilhas (tracks)**

Círculos concêntricos na superfície do prato, com 50K–100K trilhas por prato em discos modernos.

---

## **Cilindro**

Conjunto da *i*-ésima trilha de todos os pratos em um mesmo alinhamento vertical.

---

## **Densidade de Setores**

Discos modernos têm de 500–1.000 setores nas trilhas internas e de 1.000–2.000 nas trilhas externas, refletindo a maior circunferência periférica.

---

### **Tempo de Acesso**

Intervalo desde a solicitação até o início da transferência, composto por tempo de busca e latência rotacional.

### **Tempo de Busca (Seek Time)**

Tempo para reposicionar o braço sobre a trilha correta, variando de 4 a 10 milissegundos em discos típicos.

### **Latência Rotacional**

Tempo para o setor aparecer sob a cabeça, variando de 4 a 11 ms (5.400 a 15.000 RPM), com média igual à metade desse valor.

---

### **Latência Total e Taxa de Transferência**

A latência total varia de 5 a 20 ms e a taxa de transferência de dados pode atingir até 200 MB/s, sendo menor nas trilhas internas.

---

## **Blocos de Disco**

Unidade lógica de alocação e recuperação, tipicamente de 4 a 16 kilobytes. Blocos menores aumentam transferências; blocos maiores desperdiçam espaço.

---

## **IOPS**

Métrica de Operações de E/S por Segundo para leituras aleatórias. Discos magnéticos atuais oferecem de 50 a 200 IOPS.

---

## **Acesso Sequencial**

Solicitações para blocos consecutivos do disco. A busca é necessária apenas para o primeiro bloco, resultando em altas taxas de transferência.

---

## **Acesso Aleatório**

Solicitações para blocos em posições arbitrárias do disco. Cada acesso requer uma busca, resultando em baixas taxas de transferência.

A tecnologia flash revolucionou o armazenamento de dados, oferecendo velocidades drasticamente superiores aos discos magnéticos.

---

### **NAND Flash**

Leitura página por página (512 bytes a 4 KB) com tempo de 20 a 100 microssegundos, com pouca diferença entre leitura sequencial e aleatória.

---

### **Limitações de Escrita**

Cada página pode ser escrita apenas uma vez e deve ser apagada antes de ser reescrita, impactando a vida útil e o desempenho.

---

### **Discos de Estado Sólido**

Usam interfaces de disco padrão orientadas a blocos, armazenando dados internamente em múltiplos dispositivos flash.

Os **SSDs** oferecem taxas de transferência de até 500 MB/seg via SATA e até 3 GB/seg via NVMe PCIe, superando amplamente os discos magnéticos tradicionais.

Os SSDs superam os discos magnéticos em praticamente todas as métricas, especialmente em operações aleatórias e leituras paralelas.

| IOPS de Leitura                                                            | IOPS de Escrita                                                            | IOPS SATA Paralelo                                                         | IOPS NVMe                                                                                |
|----------------------------------------------------------------------------|----------------------------------------------------------------------------|----------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| Leituras aleatórias de 4 KB atingem cerca de 10.000 operações por segundo. | Escritas aleatórias de 4 KB atingem cerca de 40.000 operações por segundo. | Leituras de 4 KB com QD-32 atingem cerca de 100.000 operações por segundo. | Leituras de 4 KB com QD-32 via NVMe PCIe atingem cerca de 350.000 operações por segundo. |

### Escritas Paralelas

SSDs suportam leituras e escritas paralelas massivas, com escritas em QD-32 podendo atingir 100.000 IOPS ou mais.

### Taxa de Transferência

Leituras/escritas sequenciais chegam a 400 MB/seg via SATA3 e de 2 a 3 GB/seg via NVMe PCIe; discos híbridos combinam cache flash com disco magnético para um compromisso entre desempenho e custo.



RAID gerencia múltiplos discos oferecendo uma visão unificada com capacidade, velocidade e confiabilidade superiores.

---

### **Alta Capacidade e Velocidade**

Múltiplos discos em paralelo oferecem capacidades e velocidades que excedem qualquer disco individual.

### **Alta Confiabilidade**

Armazenamento redundante permite recuperação de dados mesmo quando discos individuais falham.

### **Desafios de Probabilidade**

A chance de falha em um conjunto de N discos é muito maior do que a falha de um disco específico.

---

### **Exemplo: MTTF de Sistema**

Com 100 discos de MTTF 100.000 h cada, o MTTF do sistema cai para apenas 1.000 h (~41 dias), evidenciando a necessidade de redundância.

A **redundância** armazena informações extras para reconstruir dados perdidos em caso de falha de disco.

---

### **Espelhamento (Mirroring)**

Duplica cada disco físico: cada escrita é realizada em ambos os discos, enquanto leituras podem ocorrer de qualquer um.

---

### **Proteção contra Falhas**

Se um disco falhar, os dados permanecem disponíveis no espelho. A perda só ocorre se ambos os discos falharem antes do reparo.

---

### **Probabilidade de Perda**

A probabilidade de falha combinada é muito pequena, exceto para modos dependentes como incêndio, colapso ou surtos elétricos.

---

### **Tempo Médio para Perda de Dados**

Com MTTF de 100.000 horas e tempo médio de reparo de 10 horas, o tempo médio para perda de dados de um par espelhado é de  $500 \times 10^6$  horas (57.000 anos).

O paralelismo em sistemas de disco busca três objetivos principais para transformar o desempenho de acesso aos dados.

---

### **Balanceamento de Carga**

Distribuir múltiplos acessos pequenos para aumentar o throughput geral do sistema.

---

### **Paralelização de Acessos**

Processar grandes acessos em paralelo para reduzir o tempo de resposta.

---

### **Melhoria de Taxa de Transferência**

Distribuir dados entre múltiplos discos através de striping para aumentar a velocidade.

---

### **Striping em Nível de Bit**

Divide os bits de cada byte entre múltiplos discos, permitindo leituras a até oito vezes a taxa de um único disco, embora o tempo de busca seja pior.

---

### **Striping em Nível de Bloco**

Com  $n$  discos, o bloco  $i$  vai para o disco  $(i \bmod n) + 1$ , permitindo que requisições a blocos distintos sejam executadas em paralelo.

Os níveis RAID definem diferentes estratégias de organização de dados, com características distintas de desempenho, redundância e custo.

### RAID Nível 0


**Striping de blocos sem redundância.** Ideal para alto desempenho onde a perda de dados não é crítica.

### RAID Nível 1


**Discos espelhados com striping de blocos.** Oferece alta confiabilidade e excelente desempenho de escrita.

### Outros Níveis RAID

Os níveis RAID 2 a 6 oferecem combinações variadas de striping, espelhamento e paridade, cada um otimizado para diferentes requisitos de desempenho, custo e confiabilidade.



**(a) RAID 0: nonredundant striping**



**(b) RAID 1: mirrored disks**

A seleção do nível RAID adequado requer análise cuidadosa de múltiplos fatores que impactam desempenho, custo e recuperação.

---

### **Custo Monetário**

Considere o investimento inicial em hardware e os custos operacionais contínuos.

---

### **Desempenho Normal**

Avalie o número de operações de I/O por segundo e a largura de banda durante operação regular.

---

### **Desempenho em Falha**

Verifique a capacidade do sistema de manter operações durante a falha de um disco.

---

### **Desempenho em Reconstrução**

Considere o tempo e o impacto no sistema durante a reconstrução de um disco falhado.

---

### **Quando usar RAID 0**

Use RAID 0 apenas quando a segurança dos dados não é crítica e os dados podem ser rapidamente recuperados de outras fontes.

Diversas técnicas avançadas otimizam o desempenho de acesso a discos, minimizando latências e maximizando throughput em sistemas de banco de dados.

---

### **Buffering**

Uso de buffer em memória para armazenar em cache blocos frequentemente acessados, reduzindo drasticamente acessos físicos ao disco.

---

### **Read-ahead**

Leitura antecipada de blocos extras de uma trilha, prevendo que serão solicitados em breve com base em padrões de acesso sequencial.

---

### **Disk-arm-scheduling**

Algoritmos que reordenam requisições de blocos para minimizar o movimento do braço do disco, como o algoritmo do elevador.

---

### **Requisições Espalhadas**

Múltiplas requisições chegam para diferentes trilhas do disco em ordem aleatória.

---

### **Direção Definida**

O braço do disco inicia o movimento em uma direção, atendendo às requisições encontradas pelo caminho.

---

### **Atendimento Sequencial**

O braço atende às requisições na ordem física de suas trilhas, minimizando movimentos bruscos.

---

### **Inversão de Sentido**


Ao atingir o limite ou a última requisição em sua direção, o braço inverte o sentido de varredura.

---

### **Movimento Otimizado**

A varredura contínua e ordenada resulta em deslocamento total do braço significativamente menor.

## Referências




---

**Elmasri & Navathe**

**Fundamentals of Database Systems**

Pearson, 2016




---

**Korth, Sudarshan & Silberschatz**

**Database System Concepts**

McGraw-Hill, 2019



---

**Özsu & Valduriez**

**Principles of Distributed Database Systems**

Springer Nature, 2019