




Sistemas de Armazenamento Físico



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



As mídias de armazenamento se dividem em **voláteis** (perdem dados sem energia) e **não-voláteis** (mantêm dados mesmo sem alimentação elétrica).

Velocidade de Acesso

O tempo de recuperação varia de nanossegundos em cache a segundos em fitas magnéticas, determinando a adequação para cada aplicação.

Custo por Unidade

Tecnologias mais rápidas geralmente apresentam custo por byte significativamente mais elevado, influenciando diretamente as decisões arquiteturais.

Confiabilidade

Diferentes mídias oferecem níveis variados de durabilidade e resistência a falhas, sendo crucial para a integridade dos dados ao longo do tempo.

A hierarquia de armazenamento organiza tecnologias de memória equilibrando velocidade, capacidade e custo.

Armazenamento Primário

Registradores e cache do processador.

Armazenamento Volátil

Memória principal (RAM).

Armazenamento Não-Volátil

Flash e memória persistente.

Armazenamento Secundário

Discos magnéticos e SSDs.

Armazenamento Terciário

Fitas magnéticas e mídia óptica.

Cache: 1–5 nanossegundos

Acesso extremamente rápido, por linha de cache.

Memória Principal: 60–100 nanossegundos

Acesso por linha de cache, ainda muito rápido.

Flash/SSD: 20–100 microssegundos

Acesso por página, ordens de magnitude mais lento.

Disco Magnético: 5–10 milissegundos

Inclui tempo de busca mecânica.

Fita Magnética: 100+ milissegundos

Acesso sequencial com tempo de posicionamento significativo.

Cabeça de leitura/escrita

Componente que magnetiza e detecta padrões magnéticos na superfície do disco.

Setores

Menor unidade de dados que pode ser lida ou escrita, tipicamente 512 bytes.

Processo de Leitura/Escrita

O braço posiciona a cabeça sobre a trilha correta, o prato gira (5.400–15.000 RPM) e os dados são lidos ou escritos conforme o setor passa sob a cabeça.

Trilhas (tracks)

Círculos concêntricos na superfície do prato, com 50K–100K trilhas por prato em discos modernos.

Cilindro

Conjunto da *i*-ésima trilha de todos os pratos em um mesmo alinhamento vertical.

Densidade de Setores

Discos modernos têm de 500–1.000 setores nas trilhas internas e de 1.000–2.000 nas trilhas externas, refletindo a maior circunferência periférica.

Tempo de Acesso

Intervalo desde a solicitação até o início da transferência, composto por tempo de busca e latência rotacional.

Tempo de Busca (Seek Time)

Tempo para reposicionar o braço sobre a trilha correta, variando de 4 a 10 milissegundos em discos típicos.

Latência Rotacional

Tempo para o setor aparecer sob a cabeça, variando de 4 a 11 ms (5.400 a 15.000 RPM), com média igual à metade desse valor.

Latência Total e Taxa de Transferência

A latência total varia de 5 a 20 ms e a taxa de transferência de dados pode atingir até 200 MB/s, sendo menor nas trilhas internas.

Blocos de Disco

Unidade lógica de alocação e recuperação, tipicamente de 4 a 16 kilobytes. Blocos menores aumentam transferências; blocos maiores desperdiçam espaço.

IOPS

Métrica de Operações de E/S por Segundo para leituras aleatórias. Discos magnéticos atuais oferecem de 50 a 200 IOPS.

Acesso Sequencial

Solicitações para blocos consecutivos do disco. A busca é necessária apenas para o primeiro bloco, resultando em altas taxas de transferência.

Acesso Aleatório

Solicitações para blocos em posições arbitrárias do disco. Cada acesso requer uma busca, resultando em baixas taxas de transferência.

A tecnologia flash revolucionou o armazenamento de dados, oferecendo velocidades drasticamente superiores aos discos magnéticos.

NAND Flash

Leitura página por página (512 bytes a 4 KB) com tempo de 20 a 100 microssegundos, com pouca diferença entre leitura sequencial e aleatória.

Limitações de Escrita

Cada página pode ser escrita apenas uma vez e deve ser apagada antes de ser reescrita, impactando a vida útil e o desempenho.

Discos de Estado Sólido

Usam interfaces de disco padrão orientadas a blocos, armazenando dados internamente em múltiplos dispositivos flash.

Os **SSDs** oferecem taxas de transferência de até 500 MB/seg via SATA e até 3 GB/seg via NVMe PCIe, superando amplamente os discos magnéticos tradicionais.

Os SSDs superam os discos magnéticos em praticamente todas as métricas, especialmente em operações aleatórias e leituras paralelas.

IOPS de Leitura	IOPS de Escrita	IOPS SATA Paralelo	IOPS NVMe
Leituras aleatórias de 4 KB atingem cerca de 10.000 operações por segundo.	Escritas aleatórias de 4 KB atingem cerca de 40.000 operações por segundo.	Leituras de 4 KB com QD-32 atingem cerca de 100.000 operações por segundo.	Leituras de 4 KB com QD-32 via NVMe PCIe atingem cerca de 350.000 operações por segundo.

Escritas Paralelas

SSDs suportam leituras e escritas paralelas massivas, com escritas em QD-32 podendo atingir 100.000 IOPS ou mais.

Taxa de Transferência

Leituras/escritas sequenciais chegam a 400 MB/seg via SATA3 e de 2 a 3 GB/seg via NVMe PCIe; discos híbridos combinam cache flash com disco magnético para um compromisso entre desempenho e custo.

RAID gerencia múltiplos discos oferecendo uma visão unificada com capacidade, velocidade e confiabilidade superiores.

Alta Capacidade e Velocidade

Múltiplos discos em paralelo oferecem capacidades e velocidades que excedem qualquer disco individual.

Alta Confiabilidade

Armazenamento redundante permite recuperação de dados mesmo quando discos individuais falham.

Desafios de Probabilidade

A chance de falha em um conjunto de N discos é muito maior do que a falha de um disco específico.

Exemplo: MTTF de Sistema

Com 100 discos de MTTF 100.000 h cada, o MTTF do sistema cai para apenas 1.000 h (~41 dias), evidenciando a necessidade de redundância.

A **redundância** armazena informações extras para reconstruir dados perdidos em caso de falha de disco.

Espelhamento (Mirroring)

Duplica cada disco físico: cada escrita é realizada em ambos os discos, enquanto leituras podem ocorrer de qualquer um.

Proteção contra Falhas

Se um disco falhar, os dados permanecem disponíveis no espelho. A perda só ocorre se ambos os discos falharem antes do reparo.

Probabilidade de Perda

A probabilidade de falha combinada é muito pequena, exceto para modos dependentes como incêndio, colapso ou surtos elétricos.

Tempo Médio para Perda de Dados

Com MTTF de 100.000 horas e tempo médio de reparo de 10 horas, o tempo médio para perda de dados de um par espelhado é de 500×10^6 horas (57.000 anos).

O paralelismo em sistemas de disco busca três objetivos principais para transformar o desempenho de acesso aos dados.

Balanceamento de Carga

Distribuir múltiplos acessos pequenos para aumentar o throughput geral do sistema.

Paralelização de Acessos

Processar grandes acessos em paralelo para reduzir o tempo de resposta.

Melhoria de Taxa de Transferência

Distribuir dados entre múltiplos discos através de striping para aumentar a velocidade.

Striping em Nível de Bit

Divide os bits de cada byte entre múltiplos discos, permitindo leituras a até oito vezes a taxa de um único disco, embora o tempo de busca seja pior.

Striping em Nível de Bloco

Com n discos, o bloco i vai para o disco $(i \bmod n) + 1$, permitindo que requisições a blocos distintos sejam executadas em paralelo.

Os níveis RAID definem diferentes estratégias de organização de dados, com características distintas de desempenho, redundância e custo.

RAID Nível 0


Striping de blocos sem redundância. Ideal para alto desempenho onde a perda de dados não é crítica.

RAID Nível 1


Discos espelhados com striping de blocos. Oferece alta confiabilidade e excelente desempenho de escrita.

Outros Níveis RAID

Os níveis RAID 2 a 6 oferecem combinações variadas de striping, espelhamento e paridade, cada um otimizado para diferentes requisitos de desempenho, custo e confiabilidade.



(a) RAID 0: nonredundant striping



(b) RAID 1: mirrored disks

A seleção do nível RAID adequado requer análise cuidadosa de múltiplos fatores que impactam desempenho, custo e recuperação.

Custo Monetário

Considere o investimento inicial em hardware e os custos operacionais contínuos.

Desempenho Normal

Avalie o número de operações de I/O por segundo e a largura de banda durante operação regular.

Desempenho em Falha

Verifique a capacidade do sistema de manter operações durante a falha de um disco.

Desempenho em Reconstrução

Considere o tempo e o impacto no sistema durante a reconstrução de um disco falhado.

Quando usar RAID 0

Use RAID 0 apenas quando a segurança dos dados não é crítica e os dados podem ser rapidamente recuperados de outras fontes.

Diversas técnicas avançadas otimizam o desempenho de acesso a discos, minimizando latências e maximizando throughput em sistemas de banco de dados.

Buffering

Uso de buffer em memória para armazenar em cache blocos frequentemente acessados, reduzindo drasticamente acessos físicos ao disco.

Read-ahead

Leitura antecipada de blocos extras de uma trilha, prevendo que serão solicitados em breve com base em padrões de acesso sequencial.

Disk-arm-scheduling

Algoritmos que reordenam requisições de blocos para minimizar o movimento do braço do disco, como o algoritmo do elevador.

Requisições Espalhadas

Múltiplas requisições chegam para diferentes trilhas do disco em ordem aleatória.

Direção Definida

O braço do disco inicia o movimento em uma direção, atendendo às requisições encontradas pelo caminho.

Atendimento Sequencial

O braço atende às requisições na ordem física de suas trilhas, minimizando movimentos bruscos.


Inversão de Sentido

Ao atingir o limite ou a última requisição em sua direção, o braço inverte o sentido de varredura.

Movimento Otimizado

A varredura contínua e ordenada resulta em deslocamento total do braço significativamente menor.


Referências



Elmasri & Navathe

Fundamentals of Database Systems


Pearson, 2016



Korth, Sudarshan & Silberschatz

Database System Concepts

McGraw-Hill, 2019



Özsu & Valduriez

Principles of Distributed Database Systems

Springer Nature, 2019