




# Benchmark TPC

Uma introdução completa aos benchmarks TPC e sua importância para avaliação de desempenho em sistemas de banco de dados

**Eduardo Ogasawara**

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# O que são Benchmarks?

## Definição

Um benchmark é uma carga padronizada utilizada no processo de avaliação e medição de desempenho de sistemas computacionais. Ele permite comparações objetivas entre diferentes configurações de hardware e software.

## Atributos Essenciais

|                                                                              |                                                                              |                                                                  |
|------------------------------------------------------------------------------|------------------------------------------------------------------------------|------------------------------------------------------------------|
| <b>Relevante</b><br>Representa cargas de trabalho reais do mundo empresarial | <b>Entendível</b><br>Facilmente compreensível por desenvolvedores e gestores | <b>Métricas bem definidas</b><br>Resultados claros e mensuráveis |
| <b>Escalável</b><br>Adaptável a diferentes tamanhos de sistemas              | <b>Alta cobertura</b><br>Testa diversos aspectos do sistema                  | <b>Bem aceito</b><br>Reconhecido pela indústria                  |

## **Benefícios dos Benchmarks TPC**

---

### **Padronização de Avaliação de Desempenho**

Define critérios e métricas padronizadas para avaliação de desempenho de sistemas de bancos de dados

---

### **Comparação Controlada de Desempenho**

Permite a comparação objetiva de desempenho entre sistemas sob cargas padronizadas e regras de execução bem definidas

### **Direcionamento de Projeto e Otimização**

Fornecer metas quantitativas que orientam decisões de projeto, otimização e avaliação de sistemas de bancos de dados

---

### **Evolução de Arquiteturas e Mecanismos**

Estimula a melhoria de arquiteturas, mecanismos de execução e estratégias de otimização a partir de cargas padronizadas

## Conselho de Desempenho TPC

O Transaction Processing Performance Council (TPC) é uma **organização sem fins lucrativos** fundada para definir benchmarks de processamento de transações e bancos de dados, além de divulgar dados de desempenho objetivos e verificáveis para a indústria.

### Missão Principal

Define regras rigorosas e testes padronizados para avaliação de desempenho de sistemas de bancos de dados

### Composição

Composta por representantes de empresas líderes do setor de tecnologia da informação

### Objetivo

Provê dados confiáveis para testes de desempenho relevantes em diversos cenários de uso empresarial

## Tipos de Benchmarks TPC

---

### TPC-C

**Benchmark OLTP** (Online Transaction Processing)

- Simula ambientes de processamento transacional
- Focado em operações de alta concorrência
- Ideal para sistemas de comércio e varejo

### TPC-H

**Benchmark OLAP** (Online Analytical Processing)

- Avalia consultas analíticas complexas
- Orientado para tomada de decisões
- Voltado para business intelligence

# Benchmark TPC-C

O TPC-C é o benchmark padrão da indústria para comparação de desempenho OLTP em diversos ambientes de hardware e software. Ele foi projetado para representar com precisão o ambiente computacional encontrado em aplicações comerciais típicas.

## Ambiente Completo

Simula um sistema com grande quantidade de usuários executando transações simultaneamente contra um banco de dados

## Transações Variadas

Executa transações concorrentes de complexidade e tipos diferentes, refletindo cenários reais

## Base Robusta

Banco de dados composto por nove tabelas inter-relacionadas com milhões de registros

 **Métrica Principal:** O resultado é medido em transações por minuto (tpmC), permitindo comparações objetivas de desempenho entre diferentes sistemas

# Transações do TPC-C

O benchmark TPC-C utiliza cinco tipos de transações que simulam atividades típicas de um ambiente de distribuição e comércio atacadista:

|                                                                                                                      |                                                                                                              |                                                                                                      |
|----------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| <b>New-Order</b><br><b>45% das transações</b><br>Insere uma nova ordem de compra de um cliente no sistema            | <b>Payment</b><br><b>43% das transações</b><br>Atualiza o saldo do cliente refletindo um pagamento realizado | <b>Delivery</b><br><b>4% das transações</b><br>Processa e atende lotes de ordens de compra pendentes |
| <b>Order-Status</b><br><b>4% das transações</b><br>Recupera o status das ordens de compra mais recentes dos clientes | <b>Stock-Level</b><br><b>4% das transações</b><br>Monitora e verifica os níveis de estoque de produtos       |                                                                                                      |

# Modelo de Dados TPC-C

## Warehouse (W armazéns)


Representa os centros de distribuição

## Stock (W × 100K itens)

Estoque por armazém

## Item (100K itens fixos)

Catálogo de produtos



O modelo de dados é escalável, permitindo ajustar o tamanho do benchmark através do número de armazéns (W). Cada armazém mantém relacionamentos complexos com clientes, pedidos e itens em estoque.



# Processo de Execução TPC-C


## Seleção de Transação

O sistema seleciona uma transação do menu baseado nas porcentagens definidas

- New-Order: 45%
- Payment: 43%
- Order-Status: 4%
- Delivery: 4%
- Stock-Level: 4%

## Think Time

Simulação do tempo de análise do usuário



## Menu Response Time

Medição do tempo de resposta da tela de entrada

## Keying Time

Simulação do tempo de digitação do usuário


## Transaction RT

Medição do tempo de resposta da transação

📄 **Tempos definidos pela especificação do benchmark TPC-C:** Os tempos de digitação (*keying time*), espera (*think time*) e resposta fazem parte da carga padronizada do benchmark e não refletem parâmetros internos do SGBD.


# Teste ACID do TPC-C

O benchmark TPC-C não apenas mede desempenho, mas também verifica rigorosamente que as propriedades ACID fundamentais de bancos de dados transacionais estão sendo respeitadas:




## Atomicidade

Confirma que todas as mudanças de uma transação são completamente confirmadas ou totalmente abortadas, sem estados intermediários




## Consistência

Verifica que o banco de dados permanece em um estado válido antes e depois de cada transação



## Isolamento

Assegura que transações concorrentes não interferem umas com as outras durante a execução



## Durabilidade

Demonstra a capacidade de recuperação do sistema em diversos cenários de falha

O TPC-C testa especificamente a durabilidade através de simulações de faltas de energia, problemas de memória e falhas em mídias de armazenamento

## Benchmark TPC-H

O TPC-H é um benchmark de suporte à decisão que examina grandes volumes de dados e executa consultas de alta complexidade. Ele foi projetado para avaliar o desempenho de sistemas de banco de dados utilizados em aplicações de **Business Intelligence** e **Data Warehousing**.



### Consultas ad-hoc complexas

Orientadas a negócio e representando análises reais



### Grande volume de dados

Examina extensas porções da base para insights profundos



### Atualizações Concorrentes Controladas

Simula ambientes analíticos onde atualizações ocorrem de forma limitada e controlada durante a execução das consultas



### Respostas críticas

Fornece informações essenciais para decisões estratégicas

## Características das Consultas TPC-H

---

### Alto grau de complexidade

Consultas envolvem múltiplas junções, agregações e subconsultas aninhadas

---

### Diversidade de Estratégias de Acesso

Exploram diferentes estratégias de acesso aos dados, incluindo varreduras completas, uso de índices e operações de junção complexas

---

### Natureza ad-hoc

Não seguem padrões previsíveis, simulando consultas exploratórias reais

---

### Processamento em Larga Escala

Processam porções significativas da base de dados para responder consultas analíticas complexas

---

### Diversidade entre consultas

Cada consulta é única e testa diferentes aspectos do sistema

---

### Parâmetros dinâmicos

Possuem parâmetros que mudam durante a execução, testando adaptabilidade

# Tipos de Consultas OLAP

O TPC-H inclui 22 consultas que cobrem cenários analíticos típicos de negócios. Estas consultas são agrupadas em cinco categorias principais:

---

## Preço e Promoção

Análises de estratégias de precificação, impacto de descontos e efetividade de campanhas promocionais

---

## Oferta e Procura

Gerenciamento de estoques, previsão de demanda e otimização da cadeia de suprimentos

---

## Lucros e Rendimentos

Análise de margens de lucro, rentabilidade por produto e performance financeira

---

## Satisfação do Cliente

Estudos de comportamento, retenção e satisfação de clientes ao longo do tempo

---

## Gerenciamento de Remessa

Otimização de logística, análise de prazos de entrega e custos de transporte

## Cenário de Execução TPC-H


### TPC-H vs TPC-C

Enquanto o TPC-C foca em transações rápidas e concorrentes, o TPC-H é projetado para consultas analíticas de longa duração que examinam grandes volumes de dados históricos.

### Neutralidade da Base de Dados


A base de dados deve ser construída conforme a especificação do TPC-H, sem otimizações específicas que favoreçam exclusivamente o benchmark.

 **Importante:** O sistema deve ser capaz de executar qualquer carga de trabalho OLAP, não apenas as consultas específicas do TPC-H



## Esquema do TPC-H

O esquema de banco de dados do TPC-H é baseado em um modelo de negócios de distribuição e vendas. Ele consiste em **oito tabelas principais** que representam entidades como clientes, pedidos, fornecedores, produtos e entregas.



### Relacionamentos Complexos

As tabelas possuem múltiplas chaves estrangeiras e relacionamentos que simulam um ambiente empresarial real

### Dados Escaláveis

O tamanho do banco pode variar de 1GB a vários terabytes através do fator de escala

### Distribuição Estatística Controlada

Os dados seguem distribuições estatísticas definidas pela especificação do TPC-H para representar padrões de negócios de forma reproduzível

## Executando o TPC-H

---

### Preparação da Base

Utilize o **DBGen** (Database Generator) para gerar os dados do benchmark

- Define o fator de escala desejado
- Cria arquivos .tbl com dados formatados
- Gera tabelas conforme especificação

---

### Preparação das Consultas

Use o **QGen** (Query Generator) para criar as 22 consultas parametrizadas

- Gera parâmetros aleatórios
- Cria variações das consultas
- Produz scripts executáveis

---

### Ferramentas Oficiais do Benchmark

Utilize o DBGen e o QGen, conforme especificação do TPC-H, para geração de dados e consultas padronizadas.



# Dicas para Carga de Dados

## Conformidade com a Especificação

A estrutura das tabelas deve seguir rigorosamente a especificação do TPC-H, pois alterações na ordem ou definição das colunas comprometem a validade dos resultados.

## Opções de Carga

---

### Opção 1: Funções Nativas

Utilize funções específicas do SGBD que permitem a carga direta de arquivos com separadores (delimitadores)

- Mais rápida e eficiente
- Aproveita otimizações do banco
- Recomendada para grandes volumes

### Opção 2: Programa Customizado

Desenvolva um programa (Java, .NET, Python) que leia os arquivos .tbl e faça a carga conectando-se à base

- Maior controle sobre o processo
- Permite transformações de dados
- Útil para debugging

## Carga via SGBD: Exemplos Práticos

Cada sistema de gerenciamento de banco de dados possui seu próprio mecanismo otimizado para carga em massa. Aqui estão exemplos de comandos para os principais SGBDs:

### PostgreSQL

```
-- Adicionar coluna temporária
alter table supplier add stub char(1);

-- Carregar dados
COPY supplier FROM '/data/tpch/supplier.tbl'
USING DELIMITERS '|' WITH NULL AS 'NULL';

-- Remover coluna temporária
alter table supplier drop column stub;
```

Observação: o comando COPY requer acesso do servidor ao arquivo; alternativamente, pode-se usar \copy via cliente.

Referência: <http://www.postgresql.org/docs/8.2/interactive/sql-copy.html>


### MySQL

```
-- Carregar dados diretamente
load data infile "/var/lib/mysql-files/region.tbl"
IGNORE INTO TABLE region
fields terminated by '|';
```

Comando simples e direto para carga de arquivos delimitados

- ❏ **Boas práticas de carga em massa:** Para cargas volumosas, recomenda-se desabilitar índices e restrições temporariamente e reativá-los após a carga, conforme suportado pelo SGBD, a fim de reduzir o custo de inserção.

## Referências




**Elmasri & Navathe**

**Fundamentals of Database Systems**

Pearson, 2016

Referência abrangente sobre fundamentos de sistemas de bancos de dados, cobrindo aspectos teóricos e práticos.



**Korth, Sudarshan & Silberschatz**

**Database System Concepts**

McGraw-Hill, 2019

Texto fundamental que serviu como base para a maioria dos exemplos apresentados nesta apresentação.



**Özsu & Valduriez**

**Principles of Distributed Database Systems**

Springer Nature, 2019

Obra especializada em sistemas de bancos de dados distribuídos, essencial para compreensão avançada.

☐ **Nota:** Os conceitos e exemplos apresentados baseiam-se principalmente na literatura clássica de sistemas de bancos de dados, em especial *Database System Concepts* e *Fundamentals of Database Systems*.